

# Cours 2 – Décrire, comparer, visualiser des données OWID

Moyenne, médiane, dispersion et premiers pas avec pandas

Etienne Dagorn

Université de Lille – L2 Économie

2026–2027

# Objectif de la séance

---

## But

Passer de petits objets Python à une première analyse descriptive : lire des données, calculer quelques indicateurs, visualiser et interpréter avec prudence.

- ▶ Python reste l'objectif principal.
- ▶ Les statistiques servent de langage pour résumer les données.
- ▶ Les exemples suivent la logique des TPs OWID.

# Où va le cours ?

---

| Séance | Python                 | Statistique support                       |
|--------|------------------------|-------------------------------------------|
| TP1    | variables, listes      | moyenne, min, max, pourcentage            |
| TP2    | boucles, conditions    | proportions, seuils                       |
| TP3    | fonctions              | comparaison de groupes                    |
| TP4    | graphiques, simulation | distribution, stabilisation d'une moyenne |
| TP5    | pandas                 | mini-projet descriptif OWID               |

## Fil rouge

Une bonne analyse décrit une distribution, pas seulement un chiffre isolé.

# Donnée, observation, variable

---

| Mot         | Sens simple            | Exemple OWID         |
|-------------|------------------------|----------------------|
| Observation | une ligne du tableau   | France en 2021       |
| Variable    | une colonne du tableau | PIB par habitant     |
| Valeur      | une case du tableau    | 46000                |
| Unité       | sens de la valeur      | dollars par habitant |

## Réflexe

Avant de calculer : quelle est l'observation ? quelle est la variable ? quelle est l'unité ?

# Même information, trois formes

---

```
valeurs = [46, 54, 34]
```

```
gdp = {  
    "France": 46,  
    "Germany": 54,  
    "Spain": 34  
}
```

```
donnees = [  
    {"pays": "France", "gdp":  
     46},  
    {"pays": "Germany", "gdp":  
     54},  
    {"pays": "Spain", "gdp":  
     34}  
]
```

## Idée

Plus les données deviennent riches, plus une table devient pratique. C'est le rôle d'un DataFrame pandas.

# Langage, bibliothèque, environnement

---

| Terme         | Rôle                              | Exemple            |
|---------------|-----------------------------------|--------------------|
| Langage       | règles pour écrire des programmes | Python             |
| Interpréteur  | programme qui lit le langage      | python3            |
| Bibliothèque  | outils ajoutés au langage         | pandas, matplotlib |
| Environnement | ensemble installé sur la machine  | Python + packages  |

## Erreur fréquente

Si `import pandas` échoue, Python fonctionne peut-être très bien : c'est la bibliothèque ou l'environnement qui manque.

# Pseudo-code : décrire une liste

---

```
# Objectif : resumer une liste de valeurs économiques
# Entree : une liste de nombres
# 1. Compter les observations
# 2. Calculer la moyenne
# 3. Trier pour trouver la mediane
# 4. Reperer minimum et maximum
# 5. Observer la dispersion
# Sortie : chiffres + interpretation courte
```

## Programmation

Le pseudo-code dit quoi faire. Python impose ensuite une syntaxe précise pour le faire.

# Moyenne et médiane : ce qu'elles disent

---

| Indicateur | Question           | Limite                        |
|------------|--------------------|-------------------------------|
| Moyenne    | niveau général     | sensible aux valeurs extrêmes |
| Médiane    | valeur centrale    | ignore l'ampleur des écarts   |
| Minimum    | plus petite valeur | ne résume pas le groupe       |
| Maximum    | plus grande valeur | peut être atypique            |

## À retenir

Moyenne et médiane résument le centre. Elles ne suffisent pas à décrire la forme de la distribution.

# Même moyenne, même médiane, distributions différentes

---

```
groupe_a = [8, 9, 10, 11, 12]  
groupe_b = [0, 5, 10, 15, 20]
```

| Groupe | Moyenne | Médiane | Lecture                 |
|--------|---------|---------|-------------------------|
| A      | 10      | 10      | valeurs concentrées     |
| B      | 10      | 10      | valeurs très dispersées |

## Question

Si ces valeurs sont des revenus, les deux groupes racontent-ils la même situation économique ?

# Distribution : regarder toutes les valeurs

---

- ▶ Une distribution décrit la façon dont les valeurs se répartissent.
- ▶ On peut regarder le centre : moyenne, médiane.
- ▶ On peut regarder les extrêmes : min, max, étendue.
- ▶ On peut regarder la dispersion : écarts à la moyenne, variance, écart-type.
- ▶ On peut visualiser : histogramme, barres, points.

## Idée économique

Deux pays ou deux groupes peuvent avoir le même niveau moyen mais des inégalités ou dispersions très différentes.

# Écarts à la moyenne

---

Pour `groupe_b = [0, 5, 10, 15, 20]`, la moyenne vaut 10.

```
ecart = valeur - moyenne
```

|        |     |    |    |    |    |
|--------|-----|----|----|----|----|
| Valeur | 0   | 5  | 10 | 15 | 20 |
| Écart  | -10 | -5 | 0  | 5  | 10 |

## Problème

Si on additionne les écarts, les valeurs négatives et positives se compensent. Il faut donc mesurer la taille des écarts autrement.

# Variance et écart-type : intuition

---

## Variance

La variance est la moyenne des carrés des écarts à la moyenne.

$$\text{variance} = \frac{1}{n} \sum (x_i - \bar{x})^2$$

- ▶ On met les écarts au carré pour éviter les compensations.
- ▶ Les grands écarts comptent davantage.
- ▶ L'écart-type est la racine carrée de la variance.
- ▶ L'écart-type revient dans l'unité de départ, donc il est plus lisible.

# Pseudo-code : variance sans panique

---

```
# Objectif : mesurer la dispersion d'une liste
# Entree : liste de valeurs
# 1. Calculer la moyenne
# 2. Pour chaque valeur :
#     calculer l'ecart a la moyenne
#     mettre cet ecart au carre
# 3. Calculer la moyenne des ecarts au carre
# 4. Prendre la racine pour obtenir l'ecart-type
# Sortie : variance et ecart-type
```

## Position dans le cours

À connaître intuitivement. En obligatoire, on insiste surtout sur moyenne, médiane, min, max et graphiques.

# Livecoding 1 : résumer deux groupes

---

Départ en direct :

```
groupe_a = [8, 9, 10, 11, 12]
groupe_b = [0, 5, 10, 15, 20]

def moyenne(valeurs):
    return sum(valeurs) / len(valeurs)

print(moyenne(groupe_a))
print(moyenne(groupe_b))
```

À coder ensemble : min, max, étendue, puis une phrase d'interprétation.

## Livecoding 2 : médiane et dispersion

---

Objectif : transformer une idée statistique en fonction Python.

```
def mediane_impair(valeurs):  
    valeurs_triees = sorted(valeurs)  
    milieu = len(valeurs_triees) // 2  
    return valeurs_triees[milieu]  
  
def etendue(valeurs):  
    return max(valeurs) - min(valeurs)
```

Question en direct : quel groupe a la plus grande étendue ? Est-ce visible dans la moyenne ?

## Livecoding 3 : variance pas à pas

---

Version volontairement explicite, pour comprendre la logique.

```
def variance(valeurs):  
    m = moyenne(valeurs)  
    carres = []  
    for x in valeurs:  
        ecart = x - m  
        carres.append(ecart ** 2)  
    return moyenne(carres)
```

Extension en direct si le groupe suit :

```
import math  
print(math.sqrt(variance(groupe_b)))
```

# Graphiques : voir ce que les chiffres cachent

---

| Graphique       | Sert à voir                   | TP            |
|-----------------|-------------------------------|---------------|
| Barres          | comparer des catégories       | TP4, TP5      |
| Histogramme     | forme d'une distribution      | TP4           |
| Courbe          | évolution dans le temps       | extension TP5 |
| Nuage de points | relation entre deux variables | plus tard     |

## Règle

Un graphique doit répondre à une question précise. Il n'est pas une décoration.

## Livecoding 4 : visualiser une distribution

---

```
import matplotlib.pyplot as plt

valeurs = [46, 54, 34, 38, 22, 61]
pays = ["France", "Germany", "Spain", "Italy", "Poland", "Sweden"]

plt.bar(pays, valeurs)
plt.xticks(rotation=45, ha="right")
plt.ylabel("PIB par habitant, milliers de dollars")
plt.tight_layout()
plt.show()
```

À demander : quel pays tire la moyenne vers le haut ?

# Lire un fichier Our World in Data

---

| Colonne OWID     | Sens           | Exemple          |
|------------------|----------------|------------------|
| Entity           | pays ou région | France           |
| Code             | code pays      | FRA              |
| Year             | année          | 2022             |
| Dernière colonne | indicateur     | PIB par habitant |

## Astuce

Les fichiers OWID ont souvent une structure régulière : identifier la colonne de valeur est la première étape.

# Pseudo-code : pipeline pandas OWID

---

```
# Objectif : deccrire un indicateur OWID
# 1. Lire le CSV depuis une URL
# 2. Afficher les premieres lignes
# 3. Renommer Entity, Code, Year, valeur
# 4. Filtrer une annee recente
# 5. Selectionner quelques pays
# 6. Calculer moyenne, mediane, min, max
# 7. Tracer un graphique
# 8. Rediger une interpretation prudente
```

## Livecoding 5 : lire un CSV OWID

---

```
import pandas as pd

url = "https://ourworldindata.org/grapher/gdp-per-capita-worldbank.csv"
df = pd.read_csv(url)

print(df.head())
print(df.shape)
print(df.columns)
```

Question : quelle colonne contient l'indicateur économique ?

## Livecoding 6 : nettoyer et filtrer

---

```
value_col = df.columns[-1]
df = df.rename(columns={
    "Entity": "country",
    "Code": "code",
    "Year": "year",
    value_col: "gdp_pc"
})

latest_year = df["year"].max()
latest = df.loc[df["year"] == latest_year].dropna(subset=["gdp_pc"])
```

À demander : pourquoi retirer les valeurs manquantes avant de calculer ?

## Livecoding 7 : calculer et comparer

---

```
pays = ["France", "Germany", "Spain", "Poland", "United States", "India"]
selection = latest.loc[latest["country"].isin(pays)].copy()

print(selection[["country", "gdp_pc"]])
print(selection["gdp_pc"].mean())
print(selection["gdp_pc"].median())
print(selection["gdp_pc"].min())
print(selection["gdp_pc"].max())
```

Interprétation : la France est-elle au-dessus ou au-dessous de la moyenne de cette sélection ?

# Décrire sans surinterpréter

---

## Phrase acceptable

Dans cette sélection de pays et pour cette année, la France est au-dessus ou au-dessous de la moyenne observée du PIB par habitant.

## Phrase trop forte

La France est plus riche parce que sa politique économique est meilleure.

- ▶ On décrit des données.
- ▶ On ne prouve pas une cause.
- ▶ On précise toujours le périmètre : pays, année, indicateur, source.

# Ce que les TPs rendent obligatoire

---

| TP  | Obligatoire                                        |
|-----|----------------------------------------------------|
| TP3 | fonctions, moyenne, médiane, min, max, comparaison |
| TP4 | graphique, simulation simple, distribution         |
| TP5 | CSV OWID, pandas, graphique, interprétation        |

## Priorité pédagogique

Écrire du Python clair avant d'empiler les notions statistiques.

# Résumé

---

- ▶ Moyenne et médiane résument le centre d'une distribution.
- ▶ Elles ne captent pas toute la dispersion.
- ▶ Variance et écart-type mesurent les écarts à la moyenne, mais restent secondaires dans ce cours.
- ▶ Les graphiques aident à voir ce qu'un chiffre unique cache.
- ▶ pandas permet de passer d'une petite liste à un vrai tableau OWID.
- ▶ Toute interprétation doit rester descriptive et prudente.