

TP5 – Mini-projet pandas avec Our World in Data

Python pour économistes – Université de Lille, L2 Économie

Question fil rouge

Comment importer un CSV OWID, produire des statistiques descriptives simples, tracer un graphique et rédiger une interprétation économique ?

Livrables

Un fichier `tp5_nom_prenom.py`, une figure `out/gdp_top10.png`, un fichier `out/gdp_selection.csv` et une interprétation de six à huit lignes.

Méthode de travail

Lire identifier les données, la question et le livrable attendu.

Décomposer écrire les étapes en pseudo-code avant de coder.

Exécuter lancer le script complet depuis le bon dossier.

Vérifier contrôler les sorties, les fichiers créés et l'interprétation.

Parcours obligatoire

Les exercices 1 à 9 sont obligatoires. Ce TP est le mini-projet final : il combine chemins de fichiers, `pandas`, statistiques descriptives simples, graphique et interprétation.

Pathways : travailler avec un CSV OWID

Le TP lit directement un CSV publié par Our World in Data. Si la connexion internet ne fonctionne pas en salle, télécharger le CSV avec un navigateur et placer le fichier dans un dossier `data`.

<https://ourworldindata.org/grapher/gdp-per-capita-worldbank.csv>

Logique 1 – Pipeline pandas final

PSEUDO-CODE

```
# Objectif : mini-projet descriptif avec un CSV OWID
# 1. Lire le CSV
# 2. Inspecter lignes, colonnes et types
# 3. Renommer les colonnes utiles
# 4. Filtrer une année et quelques pays
# 5. Calculer moyenne, médiane, min, max
# 6. Tracer un graphique lisible
# 7. Exporter un tableau propre
# 8. Rédiger une interprétation prudente
```

A. Importer et inspecter

Exercice 1 – Préparer le script**OBLIGATOIRE**

Créer l'arborescence suivante :

```
TP5/  
  tp5_nom_prenom.py  
  out/
```

Dans le script, créer le dossier `out`.

```
from pathlib import Path  
  
out_dir = Path("out")  
out_dir.mkdir(exist_ok=True)
```

Exercice 2 – Lire le CSV OWID**OBLIGATOIRE**

Lire le fichier depuis l'URL OWID.

```
import pandas as pd  
  
url = "https://ourworldindata.org/grapher/gdp-per-capita-worldbank.csv"  
df = pd.read_csv(url)  
  
print(df.head())  
print(df.shape)  
print(df.columns)
```

Ajouter un commentaire indiquant le nombre de lignes et de colonnes.

Exercice 3 – Renommer proprement**OBLIGATOIRE**

Le nom de la colonne de valeur peut être long. On le récupère automatiquement.

```
value_col = df.columns[-1]  
  
df = df.rename(columns={  
    "Entity": "country",  
    "Code": "code",  
    "Year": "year",  
    value_col: "gdp_pc"  
})
```

Afficher `df[["country", "year", "gdp_pc"]].head()`.

B. Filtrer et décrire**Exercice 4 – Sélectionner une année récente****OBLIGATOIRE**

Créer un tableau `latest` avec la dernière année disponible dans le fichier, puis retirer les valeurs manquantes.

```
latest_year = df["year"].max()  
latest = df.loc[df["year"] == latest_year].copy()  
latest = latest.dropna(subset=["gdp_pc"])  
print(latest_year)
```

```
print(latest.shape)
```

Exercice 5 – Sélectionner quelques pays

OBLIGATOIRE

Créer une liste de pays et filtrer le tableau.

```
pays_selection = [
    "France", "Germany", "Spain", "Poland",
    "United States", "China", "India", "Brazil"
]
selection = latest.loc[latest["country"].isin(pays_selection)].copy()
print(selection[["country", "gdp_pc"]])
```

Exercice 6 – Statistiques descriptives simples

OBLIGATOIRE

Sur selection, calculer :

- a. moyenne ;
- b. médiane ;
- c. minimum ;
- d. maximum ;
- e. proportion de pays au-dessus de la moyenne de la sélection.

On peut utiliser `mean()`, `median()`, `min()` et `max()`.

C. Graphique et export

Exercice 7 – Graphique du top 10

OBLIGATOIRE

Créer un graphique en barres des dix pays les plus élevés dans latest.

```
import matplotlib.pyplot as plt

top10 = latest.sort_values("gdp_pc", ascending=False).head(10)
ax = top10.plot(kind="bar", x="country", y="gdp_pc", legend=False)
ax.set_xlabel("Pays")
ax.set_ylabel("PIB par habitant")
ax.set_title(f"Top 10 du PIB par habitant - {latest_year}")
plt.xticks(rotation=45, ha="right")
plt.tight_layout()
plt.savefig(out_dir / "gdp_top10.png", dpi=300)
```

Exercice 8 – Exporter un tableau propre

OBLIGATOIRE

Exporter selection dans out/gdp_selection.csv avec seulement country, code, year, gdp_pc.

```
selection[["country", "code", "year", "gdp_pc"]].to_csv(
    out_dir / "gdp_selection.csv",
    index=False
)
```

Exercice 9 – Interprétation finale**OBLIGATOIRE**

Ajouter six à huit lignes de commentaire :

- a. année étudiée ;
- b. pays le plus élevé dans la sélection ;
- c. pays le plus faible dans la sélection ;
- d. moyenne et médiane de la sélection ;
- e. comparaison de la France à la moyenne ;
- f. limite : choix des pays ;
- g. limite : le PIB par habitant ne mesure pas toutes les dimensions du développement.

D. Extension facultative**Extension 1 – Pour les étudiants plus rapides**

Choisir au moins deux questions si le mini-projet est terminé.

- a. Tracer uniquement les pays de la sélection.
- b. Comparer la France à l'Allemagne, aux États-Unis et à la Chine.
- c. Créer une colonne `above_selection_mean`.
- d. Exporter le `top10` dans `out/gdp_top10.csv`.
- e. Tracer l'évolution du PIB par habitant de la France depuis 1990.
- f. Ajouter le monde "World" si présent dans le fichier.
- g. Remplacer `latest_year` par une année choisie manuellement.
- h. Calculer le rapport entre le maximum et le minimum de la sélection.
- i. Importer aussi l'espérance de vie depuis <https://ourworldindata.org/grapher/life-expectancy.csv>.
- j. Extension avancée : fusionner PIB par habitant et espérance de vie pour une même année.